

0726_이신영

주제 스터디

구체화 - 손 추적 Occlusion 복원

데이터셋

메인 학습/평가용: SHREc'17 Track

- 28명이 한 손가락 또는 손 전체로 수행한 2800개의 스켈레톤 시퀀스로 구성되고, 1960개 시퀀스는 학습용, 840개는 테스트용으로 나뉘어 있음. 각 제스처는 1~10회 반복되고, 시퀀스 길이는 20~50 프레임 사이로 다양함. 각 프레임은 Intel RealSense 카메라 기준 22개 관절 좌표(손바닥 중심 1개, 손목 1개, 손가락마다 끝/중간관절 2개/기저 총 4개)로 구성됨.
- 14-class(손 전체 동작 중심)와 28-class(손가락 사용 방식까지 구분) 두 가지 라벨 체계 제공.

보조/일반화 검증용: DHG-14/28

- SHREC'17과 유사하게 20명이 수행한 2800개 시퀀스, Intel RealSense로 캡처한 22개 관절 3D 좌표를 제공하며, leave-one-subject-out 교차검증(19명 학습, 1명 테스트를 20회 반복)이 표준 평가 프로토콜임.
- SHREC와 데이터 성격이 비슷해서, "SHREC로 학습한 모델이 DHG에서도 일반화되는가"를 보는 교차 데이터셋 검증용으로 쓰기 좋음.

파이프라인 상세

1단계 — 데이터 준비

SHREC'17 로드 → 21개 관절로 스킵 통일 → 손목 기준 상대좌표 변환 → 스케일 정규화(손 크기 차이 제거)

2단계 — 가림(occlusion) 구간 합성

각 시퀀스에서 랜덤 시작점 선택 → 길이 $L(=5, 10, 20, 30 \text{ 프레임})$ 만큼 마스킹
입력: 마스킹 직전 N 프레임 ($N=10\sim15$ 권장)
정답(target): 마스킹된 L 프레임의 실제 좌표

- L 을 여러 값으로 바꿔가며 실험셋을 각각 구성

3단계 — 베이스라인 A (물리 기반)

- **등가속도 외삽**: 직전 N 프레임에서 최소자승으로 속도·가속도 추정 → 다항식으로 L 프레임 외삽
- **칼만 필터**: 상태벡터 = $[x, y, z, vx, vy, vz]$ (21개 관절 각각에 독립적으로, 또는 손 전체를 하나의 강체로 가정한 버전도 비교 가능) → 가림 구간에서는 update 없이 predict만 반복

4단계 — 베이스라인 B (학습 기반)

- **LSTM/GRU seq2seq**: 인코더(N 프레임 입력) → 컨텍스트 벡터 → 디코더(L 프레임 좌표 순차 생성)
- **Transformer**: 인코더-디코더 구조, 또는 디코더만으로 auto-regressive 생성
- 입력 특징: 21개 관절 $\times 3(x,y,z) = 63$ 차원 벡터의 시퀀스 (상대좌표 기준)

5단계 — 하이브리드

- 규칙 기반 전환: $L \leq \text{threshold}(\text{예: } 10\text{프레임})$ 면 칼만 필터, 그 이상이면 학습 모델
- (여유 있으면) 잔차 방식: 칼만 필터 예측값 + 학습 모델이 그 잔차(오차)를 보정하는 구조

6단계 — 평가

- MPJPE(Mean Per Joint Position Error) — 관절별 평균 위치 오차, 스켈레톤 예측에서 표준적으로 쓰이는 지표
- 가림 길이 L 별 오차 곡선 (물리/학습/하이브리드 3개 곡선을 한 그래프에)
- FPS(추론 속도) 비교
- 정성 데모: 원본 시퀀스 위에 예측 궤적 오버레이한 GIF

MediaPipe Hands: On-device Real-time Hand Tracking

<https://arxiv.org/pdf/2006.10214>

- 단일 카메라로부터 사람의 손 골격을 예측하는 on-device hand tracking solution
- 기존 연구
 - 깊이 센서와 같은 특수 하드웨어 필요
 - 일반적 모바일 기기에서 실시간 동작 어려움
- 파이프라인
 1. 손바닥 검출기
 - a. 손의 bbox 제공
 2. 손 랜드마크 모델
 - a. 손의 골격 예측
 - i. x,y 좌표와 상대 깊이
 - ii. 손이 존재할 확률
 - iii. 오른손/왼손 판별
 - b. 고정밀 2.5D 랜드마크 반환
- 의의
 - 추가 하드웨어 없이 단일 카메라만으로 2.5D hand pose 예측 가능
 - 높은 예측 품질
 - 모바일 GPU에서 실시간 추론 속도

SHREC'17 Track: 3D Hand Gesture Recognition Using a Depth and Skeletal Dataset

<https://hal.science/hal-01563505v1/file/17-EG3DOR-SHREC-Hand-Gesture-DeSmedt.pdf>

- 손 제스처 인식 task
 - 14개의 손 제스처를 포함하는 데이터셋 사용
 - VR, AR 등에서 직관적인 인터페이스 구성에 사용 가능
 - 손 자체가 복잡한 topology → 동일한 제스처 수행 방법도 다양
- 두 가지 접근법
 - static
 - 3d depth 정보 → 손 실루엣 추출 → 특징 추출
 - dynamic
 - 제스처를 손 모양의 연속으로 간주 → 시간적 특성 활용
- SHREC'17 Track
 - 두 접근법 모두에서 사용 가능
 - 28명의 참가자가 같은 제스처를 서로 다른 두 손가락 개수로 수행하여 구성
 - 14개의 손 제스처
 - swipe, pinch/expand, open/close, grab, shake 등등
 - 한 손가락 방식, 손 전체 방식의 두가지 방법으로 수행
 - 제스처 종류, 사용 손가락 개수, 참가자, 시도에 대한 라벨
 - 총 2800개의 시퀀스
 - 모두 오른손잡이

An Introduction to the Kalman Filter

<https://cis.temple.edu/~latecki/Courses/CIS750-03/Papers/KalmanFilterSIGGRAPH2001.pdf>

Kalman Filter

- 센서 자체의 noise 혹은 측정값이 없는 부분에서 가장 그럴듯한 위치를 반복적으로 추정하는 알고리즘
- 현재의 상태 state로서 현재 시스템의 상태를 벡터로 표현

- 상태 벡터 $x = [\text{위치}(x, y, z), \text{속도}(v_x, v_y, v_z)]$
- 매 프레임마다 두 단계를 반복
 1. Predict
 - a. 물리 법칙만 가지고 이전 상태에서 다음 상태 추측
 - b. $x_{\text{predicted}} = F \times x_{\text{previous}}$
 - i. F : 상태가 시간에 따라서 어떻게 변하는지를 나타내는 행렬
 - c. $P_{\text{predicted}} = F \times P_{\text{previous}} \times F^T + Q$
 - i. P : 불확실성을 표현하는 공분산 행렬
 - ii. Q : 물리 모델 자체가 얼마나 부정확한지에 대한 가정을 미리 넣어둠
 2. Update
 - a. 실제 측정값이 들어오면 예측값에 실측값을 섞어 더 정확한 추정치 생성
 - b. Kalman Gain K
 - i. $K = \text{"예측이 얼마나 불확실한가"} / (\text{"예측의 불확실성"} + \text{"측정의 불확실성"})$
 - ii. 측정이 정확하면 (노이즈 적으면) $\rightarrow K$ 커짐 $\rightarrow$ 측정값을 더 많이 믿음
 - iii. 예측이 정확하면 $\rightarrow K$ 가 작아짐 $\rightarrow$ 예측값을 더 많이 믿음
 - c. 최종 추정치
 - i. $x_{\text{final}} = x_{\text{predicted}} + K \times (\text{측정값} - x_{\text{predicted}})$
 - ii. 가중평균과 같음

Predict

Predicted state estimate $\hat{\mathbf{x}}_{k|k-1} = \mathbf{F}_k \hat{\mathbf{x}}_{k-1|k-1} + \mathbf{B}_k \mathbf{u}_k$

Predicted error covariance $\mathbf{P}_{k|k-1} = \mathbf{F}_k \mathbf{P}_{k-1|k-1} \mathbf{F}_k^T + \mathbf{Q}_k$

Correct

Innovation residual $\tilde{\mathbf{y}}_k = \mathbf{z}_k - \mathbf{H}_k \hat{\mathbf{x}}_{k|k-1}$

Innovation covariance $\mathbf{S}_k = \mathbf{H}_k \mathbf{P}_{k|k-1} \mathbf{H}_k^T + \mathbf{R}_k$

Optimal Kalman gain $\mathbf{K}_k = \mathbf{P}_{k|k-1} \mathbf{H}_k^T \mathbf{S}_k^{-1}$

Corrected state estimate $\hat{\mathbf{x}}_{k|k} = \hat{\mathbf{x}}_{k|k-1} + \mathbf{K}_k \tilde{\mathbf{y}}_k$

Corrected estimate covariance $\mathbf{P}_{k|k} = (\mathbf{I} - \mathbf{K}_k \mathbf{H}_k) \mathbf{P}_{k|k-1}$

우리 프로젝트와의 연관성

- Occlusion 상황
 - 가려진 구간에서 측정값 자체가 없음
 - Update 단계를 아예 건너뛰고 Predict만 해야함
 - 그렇게 되면 불확실성 P가 계속 누적되어 커짐
- 등가속도 외삽은 Kalman filter의 단순화 버전처럼 생각 가능
 - but 가림 상황에서는 Kalman filter도 Predict만 반복하기에 수학적으로 비슷해질 수 있음
- State vector에 가속도까지 넣을지 말지도 구현하여 비교해보면 좋음