

0806_오은하

SILK 논문 정리 & 프로젝트 적용 방안

원문: SILK: Smooth InterpoLation framework for motion in-betweening — A Simplified Computational Approach

저자: Elly Akhouni, Hung Yu Ling, Anup Deshmukh, Judith Bütetage (SEED, Electronic Arts) / CVPR 2025 HuMoGen Workshop

논문: <https://arxiv.org/abs/2506.09075> · 공식 페이지: <https://silk-paper.github.io/>

1. Motion In-betweening 정의

Motion prediction(예측)과 motion in-betweening은 구분되는 개념임.

구분	설명
Motion Prediction (예측)	과거 프레임만으로 미래를 추정. 미래 정답은 미지의 상태
Motion In-betweening	과거 프레임과 미래의 특정 시점(정답)을 모두 알고 있는 상태에서 그 사이를 채움

In-betweening은 양쪽 끝의 정보를 모두 활용하므로 제약 조건이 많고, 그만큼 정확도가 높게 나타남. 애니메이션 업계에서 원화(키프레임) 사이를 자연스럽게 잇는 작업(동화)에서 유래한 개념임.

2. SILK 아키텍처 요약

- **입력:** 문맥(context) 프레임, 빈 프레임(예측 대상, 0으로 채움), 목표(target) 키프레임을 하나의 시퀀스로 연결
- **모델:** Transformer 인코더 단일 구조만 사용(인코더-디코더 구조 아님, 다단계 학습 없음)
- **출력:** 빈 프레임 전체를 한 번에 예측(non-autoregressive). 순차 생성 방식이 아님
- **위치 정보:** 상대적 위치 인코딩(relative positional encoding)만 사용

- **손실 함수:** L1 사용(L2/MSE 대비 학습 안정성 및 결과가 우수한 것으로 확인됨)

3. 핵심 발견

① 인코더 단일 구조

기존 연구들은 다중 인코더 또는 2단계 파이프라인(개략적 예측 모델 + 정교화 모델)을 사용했으나, SILK는 인코더 하나로 동등하거나 더 나은 성능을 달성함.

② 상대적 위치 인코딩만

"키프레임과의 근접도" 등 추가 신호 없이, 프레임 간 상대 거리 정보와 값이 0인지 여부만으로 충분한 것으로 확인됨. 단, 빈 구간을 선형보간(SLERP)으로 채우는 경우에는 이 추가 신호가 일부 도움이 되었으나, 학습 시 접하지 못한 긴 구간으로 일반화할 때는 오히려 성능을 저하시킨 것으로 나타남.

③ 빈 프레임은 선형보간이 아닌 0으로 채움

- 선형보간으로 채울 경우 모델이 해당 값 부근에서 벗어나지 못하는 편향이 발생함
- 0으로 채울 경우 "정보 없음"이라는 명확한 신호가 되어, 모델이 양측 문맥만으로 자유롭게 추론 가능함
- 가림 길이가 길어질수록 두 방식의 성능 차이가 확대됨

④ 촘촘한 샘플링으로 동일 데이터에서도 학습 샘플 수 확보

- 원본 시퀀스를 학습용 조각으로 분할할 때 겹치는 간격을 촘촘하게(offset 5) 설정하면 기존 대비 약 4배의 학습 샘플 확보 가능
- 단, 이 효과는 단순 모델(SILK)에서만 뚜렷했으며, 복잡한 모델(TST)에서는 효과가 없거나 오히려 과적합이 발생함

⑤ 관절 좌표 표현 기준(pose representation)이 성능에 유의미한 영향을 미침

- "루트(전체 기준점) 기준 좌표" 방식과 "부모관절 기준 좌표" 방식을 비교한 결과, 루트 기준 방식이 우수함

⑥ 속도(velocity)를 입력 특징에 포함

- 입력에는 속도(직전 프레임 대비 변화량) 정보를 포함하되, 예측 정답에는 속도를 포함하지 않는 조합(Input Vel)이 최적의 결과를 보임

- 속도까지 예측 대상에 포함할 경우(Full Vel) 출력 공간이 복잡해지고 오차가 누적되어 오히려 학습 난이도가 상승하는 것으로 나타남
- 속도 정보가 전혀 없는 경우(Static Only)가 세 조건 중 가장 낮은 성능을 보임

4. 실험 결과 요약

- 데이터셋: LaFAN1(Ubisoft 공개, 약 4.5시간 분량, 이동·격투·댄스·조준·낙상 및 회복 등 다양한 동작 포함)
- 학습/평가 분할: 1~4번 대상자 데이터로 학습, 5번 대상자 데이터로 평가(기존 연구와 동일 프로토콜)
- 평가 지표: L2P(거리 오차), L2Q(전역 회전 오차), NPSS(움직임의 자연스러움을 측정) — 세 지표 모두 수치가 낮을수록 우수
- 가림 길이 5·15·30·45프레임 조건에서 평가 수행(학습은 5~30프레임까지만 수행하였으며, 45프레임은 학습 시 접하지 못한 길이로 일반화 성능을 확인하기 위함)
- 결과: SILK는 구조가 훨씬 복잡한 기존 SOTA 모델(TST, Delta-Interpolator 등) 대비 대부분의 조건에서 동등하거나 우수한 성능을 보임. 특히 짧은 구간(5·15프레임)에서는 대부분의 모델이 유사한 결과를 보이는 반면, 긴 구간(30·45프레임)일수록 모델 간 성능 차이가 뚜렷하게 드러남

5. 프로젝트 적용 방안

본 논문의 시사점은 크게 두 가지로 정리됨.

1. 데이터 구성 방식(촘촘한 샘플링, 속도 특징 포함, 좌표 표현 기준)이 모델 구조의 복잡도보다 성능에 더 큰 영향을 미친다는 점이며, 이는 본 프로젝트의 데이터 파이프라인(전처리, occlusion 샘플 생성)에 직접 적용 가능함.
2. 빈 구간을 물리 모델 예측값으로 미리 채워 입력에 사용하는 방식은 지양하되(발견 ③), 물리 모델 예측값을 최종 출력에 더하는 잔차(residual) 방식은 유효함(Delta-Interpolator 사례 참조). 세부 적용 항목(데이터 증강, 손실 함수 변경, 포즈 표현 비교 실험 등)은 우선순위를 정할 필요가 있음.

Robust Motion In-betweening 논문정리

원문: Robust Motion In-betweening

저자: Félix G. Harvey, Mike Yurick, Derek Nowrouzezahrai, Christopher Pal
(Polytechnique Montreal / Ubisoft Montreal) / ACM SIGGRAPH 2020 (ACM Trans. Graph. 39, 4)

논문: <https://static-wordpress.ubisoft.com/montreal.ubisoft.com/wp-content/uploads/2020/07/09155337/RobustMotionInbetweening.pdf>

1. 검토 배경

본 논문은 SILK 논문의 관련 연구에서 언급된 RTN(Recurrent Transition Networks) 계열의 발전형이며, SILK를 포함한 이후 motion in-betweening 연구 대부분이 표준 벤치마크로 사용하는 LaFAN1 데이터셋을 제작한 논문임. SILK가 "인코더 하나로 충분하다"고 주장한 비교 대상이 본 논문의 아키텍처임.

2. 문제의식

기존 모션 예측 모델(과거 프레임으로 미래를 추정하는 모델)에 목표 키프레임 조건만 추가하면 자연스러운 transition이 생성될 것으로 예상되었으나, 실제로는 두 가지 한계가 발생함.

- 전환 길이가 달라지면 대응하지 못함(고정 길이에만 최적화됨)
- 항상 동일한 동작만 생성함(결정론적 구조로 인한 다양성 부재)

본 논문은 이 두 문제를 해결하는 것을 핵심 목표로 함.

3. 아키텍처 요약

RTN 구조를 기반으로 인코더 3개를 사용함.

인코더	입력
state encoder	현재 캐릭터 자세(관절 회전 쿼터니언 + 루트 속도 + 발 접촉 여부)
offset encoder	목표까지 남은 차이(위치·회전 오프셋)
target encoder	목표 키프레임

세 인코더의 출력을 결합해 LSTM에 입력하고, LSTM 출력을 디코더가 받아 다음 프레임을 한 스텝씩 순차 생성함(autoregressive — SILK가 non-autoregressive 일괄 생성으로 대체한 부분). 예측된 회전값은 forward kinematics(FK)로 전역 좌표로 변환해 위치 손실 계산에 사용함.

4. 핵심 기여

① Time-to-arrival embedding

Transformer의 positional encoding과 동일한 사인·코사인 함수를 사용하되, "문장에서 몇 번째 단어인가" 대신 "목표까지 몇 프레임 남았는가"를 인코딩함. 이를 LSTM 입력에 더하면 모델이 도착 시점을 인지하게 되어, 전환 끝부분에서 흔들리거나 멈칫하는 현상이 사라짐. 학습 시 접한 길이보다 긴 전환에 일반화할 때를 대비해, 특정 길이 이상에서는 임베딩 값을 고정하는 장치를 추가함.

② Scheduled target noise

동일한 시작/끝 키프레임이 주어져도 매번 다른 동작을 생성할 수 있도록(다양성 확보) 목표 임베딩에 노이즈를 더함. 노이즈 크기는 전환 초반에는 크고 목표에 가까워질수록 0으로 줄어듦(마지막 5프레임은 노이즈 없음). 노이즈 벡터를 입력에 단순히 이어붙이는 방식은 모델이 노이즈를 무시하도록 학습되어 효과가 없었으며, 임베딩에 직접 더하는 방식이 효과적인 것으로 확인됨.

5. Adversarial Loss(GAN)

단기 critic(2프레임 구간)과 장기 critic(10프레임 구간) 두 개의 discriminator를 추가함. 생성된 동작과 실제 모션을 구별하도록 학습시켜, reconstruction loss만 사용할 때 발생하는 평균화된 흐릿한 동작과 발 미끄러짐 문제를 완화함. Least-Square GAN(LSGAN) 방식을 사용함.

6. 손실 함수 및 학습 방식

- 쿼터니언 손실, 루트 위치 손실, FK 기반 전역 위치 손실, 발 접촉 손실을 모두 **L1**로 계산하고 adversarial loss를 추가로 합산함(SILK와 동일하게 L1 채택)
- Curriculum learning: 짧은 전환(5프레임)부터 학습을 시작해 점진적으로 최대 길이까지 늘려가는 방식을 사용함. 학습 초반 속도 및 안정성 개선에 기여함

7. LaFAN1 데이터셋

본 논문이 공개한 데이터셋으로, 이후 motion in-betweening 연구의 표준 벤치마크로 사용됨.

- 약 49만 6천 프레임(30Hz), 5명의 피험자가 수행한 이동·격투·댄스·조준·낙상 및 회복 등 다양한 동작 포함
- 1~4번 피험자로 학습, 5번 피험자로 평가하는 프로토콜을 정립 — SILK를 포함한 후속 연구 대부분이 동일 프로토콜 사용

8. 실험 결과 요약

- Human3.6M 워킹 서브셋과 LaFAN1 양쪽에서 평가 수행
- 단순 선형보간(interpolation) 대비, 제안한 두 임베딩 및 adversarial loss를 순차적으로 추가할 때마다 L2Q(회전 오차)·L2P(위치 오차)·NPSS(움직임 자연스러움) 세 지표가 개선됨
- LaFAN1에서는 짧은 5프레임 구간에서도 보간보다 우수한 성능을 보였으며, 긴 구간(45프레임)으로 갈수록 격차가 확대됨 — SILK 논문에서도 동일한 경향이 관찰됨

9. SILK와의 연결점

SILK의 핵심 발견들은 본 논문의 설계를 반박·단순화하는 형태로 구성되어 있음.

- 3개 인코더 + LSTM + GAN의 복잡한 구조 → Transformer 인코더 하나로 대체 (SILK 발견 ①)
- Time-to-arrival embedding 등 추가 위치 신호 → 상대적 위치 인코딩만으로 대체 (SILK 발견 ②)
- 오토리그레시브 순차 생성 → non-autoregressive 일괄 생성으로 대체

즉 본 논문은 정교하지만 복잡한 초기 접근법이며, SILK는 그 복잡함이 실제로는 필요하지 않았음을 보인 후속 연구로 이해할 수 있음.

10. 프로젝트 적용 방안

- **Curriculum learning:** 짧은 가림 길이(L=5)부터 학습을 시작해 점진적으로 긴 가림 길이(L=30)까지 확장하는 방식을 학습 스케줄에 적용 가능
- **물리적 제약 손실:** 발 접촉 손실과 같은 "물리적 타당성" 제약 개념을 손 관절의 자연스러움 제약(예: 손가락 간 거리 제약)으로 변형해 적용 가능
- **Adversarial loss:** 평균화된 흐릿한 예측 문제가 발생할 경우, 간단한 discriminator를 추가해 완화하는 방향 검토 가능(구현 난이도는 상대적으로 높음)