

0811 사전학습 데이터셋 & 모델 구현

1. 프로젝트 개요

손 추적(hand tracking)이 가려짐(occlusion)으로 인해 연속된 여러 프레임의 좌표를 통째로 잃어버렸을 때, 이를 복원하는 문제를 다룸. 물리 기반 방법(등속/등가속도 외삽, 칼만 필터)과 학습 기반 방법(Transformer)을 비교하고, 가림 길이($L=5/10/20/30$)에 따라 어느 방법이 유리한지 분석하는 것이 핵심 연구 질문.

2. 메인 데이터셋: SHREC'17

최종 확정 데이터셋: SHREC'17 Track (De Smedt et al., 2017)

- Intel RealSense 깊이 카메라로 촬영, 22개 관절(0=손목, 1=손바닥 중심, 2~21=손가락) 3D 좌표 제공
- 공식 train(1960)/test(840) 스플릿 검증 완료 (subject 겹침 없음, 프레임 수 불일치 0건)
- 시퀀스 길이: 최소 7, 최대 171, 평균 58.9프레임

SHREC를 최종 채택한 이유: RealSense 하드웨어+SDK가 만든 독립적인 정답인 반면, EgoGesture3D는 이미 MediaPipe 자신이 만든 결과물이라 우리가 연구하려는 오차 원인(추적 노이즈)이 정답 자체에 섞여 있었기 때문.

3. 사전학습용 대규모 데이터셋 탐색 — 실패 이유

- 물리 기반 방법과 달리, Transformer 기반 학습 모델은 SHREC(2,800개 시퀀스)만으로는 데이터가 부족할 수 있어 대규모 데이터로 먼저 사전학습 → SHREC으로 파인튜닝하는 전략을 세움
- 이 과정에서 여러 데이터셋을 검토함.

1. InterHand2.6M — 규모 착시 발견

- Meta(구 Facebook)가 공개한 데이터셋, 공식 홈페이지에서 `joint_3d.json` (관절 좌표) 직접 다운로드 가능해서 접근성 굿
- **문제:** 공식 통계(30fps train 약 570만 프레임)와 달리 실제로 다운로드해서 세어보니 **train 78,467개뿐**
- **원인:** InterHand2.6M은 80~140대 카메라로 동시 촬영하는 멀티뷰 스튜디오 방식인데, 공식 통계의 "프레임 수"가 **카메라 대수만큼 곱해진 이미지 수**였음. 실제 3D 자세(시간축 유니크 프레임)는 그 수치를 카메라 대수로 나눈 값에 가까움
- 이후 확인한 DexYCB(공식 논문이 스스로 "8개 시점 프레임을 합산한 수치"라고 각주에 명시)도 동일한 함정 확인
- → 결과적으로 InterHand2.6M, DexYCB, H2O 모두 "발표된 숫자"와 "실제 유니크 프레임 수"가 5~8배 차이 남

2. BigHand2.2M — 접근 자체가 불가능

- 카메라 1대 + 자기 센서 6개(손톱 5개+손등 1개) 방식이라 **멀티뷰 곱셈 문제가 없는 유일한 진짜 대규모(220만 프레임) 데이터셋**
- **접근 문제:** 공식 서버(`143.248.41.4` , ICVL 연구실 자체 호스팅)가 완전히 응답 없음 (`wget` 으로 접속은 되는데 데이터가 전혀 안 옴 — 죽은 서버로 판단)
- 대안으로 시도한 구글 폼 신청(자동 다운로드 URL 발급) 경로도 결국 같은 죽은 서버로 연결됨
- **추가 문제:** 그나마 공개적으로 접근 쉬운 서브셋(HANDS2017 챌린지용)은 공식적으로 **"시간 정보를 제거하기 위해 무작위로 섞여있다"**고 명시되어 있어서, 설령 받더라도 연속 시퀀스가 필요한 우리 프로젝트(in-betweening)에는 애초에 쓸 수 없는 데이터였음
- **결론:** 접근 불가 + 사용 가능한 서브셋은 목적에 안 맞춤 → 완전히 포기

4. 최종 선택: H2O 데이터셋

ETH Zurich에서 공개한 데이터셋 (Kwon et al., "H2O: Two Hands Manipulating Objects for First Person Interaction Recognition")

- 접근 경로: h2odataset.ethz.ch 에서 이메일 등록 → 자동으로 계정 정보 발급 (InterHand2.6M/BigHand2.2M과 달리 대기 없이 즉시 진행 가능했음)
- 검증된 실제 규모: 5대 카메라 동시 촬영, 발표된 "571,645프레임"도 멀티뷰 곱셈이 섞여 있었지만($571,645 \div 5 \approx 114,200$), 실제 다운로드해서 확인한 유니크 손 시퀀스는 **333개, 평균 619.5프레임**(SHREC 평균 58.9프레임보다 10배 이상 김) — 사전학습에 쓰기 충분한 규모로 확인됨
- 약간의 문제: 시퀀스 자체는 333개로 많지 않아서 한 시퀀스에서 중복 없이 여러 구간을 뽑음
- 4명의 피험자, subject 단위로 train(3명)/val(1명) 분리 → 데이터 누수 없음

다운로드 시 주의점 — 필요한 파일만 선별

전체 데이터셋은 RGB-D 영상까지 포함하면 피험자 1명당 176~208GB에 달함.

우리는 3D 손 좌표만 필요

- 받은 것: [subject1~4_pose_v1_1.tar.gz](#) (각 75~85MB) + [label_split.zip](#) (252KB)
- 안 받은 것: RGB-D 원본, 1인칭 영상, MANO 파라미터, 오브젝트 라벨 등

전처리 파이프라인

1) 폴더 구조 및 파일 포맷 파악

```
subject{1-4}/{액션}/{시행번호}/cam4/hand_pose/{프레임번호}.txt
```

각 텍스트 파일은 128개 값 = $[\text{왼손 존재flag}(1) + 21\text{관절} \times 3\text{좌표}(63)] + [\text{오른손 존재flag}(1) + 21\text{관절} \times 3\text{좌표}(63)]$

2) 연속 시퀀스로 재구성

- 각 take(시행) 폴더 안의 프레임 번호가 실제로 연속적인지 검증(0~N-1까지 빠짐없음 확인)
- 왼손/오른손을 각각 독립된 시퀀스로 분리 추출 → 184개 take에서 333개 손 시퀀스 확보

3) 정규화

- 손목 기준 상대좌표 변환

- 스케일 정규화는 특정 손가락 인덱스에 의존하지 않고 **21개 관절까지의 평균 거리**로 계산(H2O의 정확한 관절 순서가 SHREC만큼 확실히 검증되지 않아 안전한 방식 채택)

5. SILK 논문 기반 학습 모델 구현

논문 검증

- **SILK**(Akhoundi et al., "SILK: Smooth Interpolation framework for motion in-betweening", CVPR 2025 워크숍, arXiv:2506.09075)
- **공식 코드는 공개되어 있지 않음**
 - 논문에 명시된 스펙을 그대로 재구현

핵심 설계 원칙(논문 그대로 채택):

- Transformer 인코더 6층, 8-head, `d_model=1024`, `d_ff=4096`, Pre-LN 구조
- AdamW + Noam 학습률 스케줄러, batch size 64
- 입력 구조: **컨텍스트 C개 프레임 + 빈(0) 구간 M개 + 목표 키프레임 1개**
- 빈 프레임에 대한 attention masking 없음(모든 프레임이 서로 attend)
- 단일 L1 손실

논문과 다르게 조정한 부분(손 도메인 특성상):

- 원 논문은 몸 전체 스켈레톤(회전 정보 포함)을 다루지만, 우리 손 데이터는 3D 좌표만 있고 회전 정보가 없어 **위치+속도만 사용**(회전 특징 전부 제외)
- "골반을 지면에 투영"하는 몸 전용 root 개념 대신, **손목을 root로 삼아 상대좌표 정규화**

H2O 사전학습 결과 (30 epoch)

L	최종(epoch 30)	최고 성능(epoch)
5	0.068	0.055 (epoch 29)
10	0.073	0.060 (epoch 29)
20	0.086	0.077 (epoch 29)

L	최종(epoch 30)	최고 성능(epoch)
30	0.114	0.096 (epoch 24)

(값은 손목 기준 정규화 좌표 단위 MPJPE, H2O 자체 검증셋 기준 — SHREC과 직접 비교하려면 파인튜닝 후 SHREC test로 재평가 필요)

시각화로 발견한 한계점

학습된 모델의 예측 결과를 3D로 애니메이션 시각화해본 결과:

- 데이터셋 자체가 작음
 - 실제 motion in-betweening의 경우 움직임이 다이나믹 (fps가 작은듯)
 - 손 데이터셋은 같은 프레임 수를 예측하더라도 fps가 큰 데이터라 움직임 자체가 크지 않음
 - fps를 낮게 샘플링 해서 하자니 데이터가 더욱 줄어들음
- 대략적인 움직임 방향은 정확했음
- 다만 **관절 간 거리(뼈 길이)가 프레임마다 미세하게 흔들리며 비틀대는 현상** 확인
- 위치를 독립적으로 회귀 예측하다 보니 뼈 길이 제약을 모델이 전혀 모르는 구조적 한계
 - 원 논문은 회전을 예측해 뼈 길이가 자동 보존되지만, 우리는 회전 정보가 없어 위치만 예측하는 과정에서 생긴 부작용
- 해결 방안(뼈 길이 손실 추가 등) 검토 필요

[attachment:2e8b2aa1-ef61-436c-87a3-c6f27d44f351:v1_SILK_baseline.mp4](#)

문제 해결 방법

기존 motion in-betweening task

- 기존 논문들의 대표 벤치마크인 LAFAN1도 마찬가지로 30fps
- 그러니까 우리와 같은 환경
- but LAFAN1은 애초에 조금 다이나믹한 데이터셋을 구성함
- 구현 방법
 - 시각화 영상들은 보통 짧은 예측들을 이어붙여서 길게 만듦
 - 단순 이어붙이기만으로는 오차 누적 문제 + 연결부 부자연스러움
 - 따라서 "**chain-of-forward training**"(학습 때부터 여러 단계를 이어붙이는 상황을 미리 시뮬레이션해서 훈련) 같은 별도 기법을 추가로 개발해서 문제를 완화

우리의 구현 방법 제안

1. Autoregressive chaining으로 긴 데모 만들기 (가장 실현 가능, 추천)

지금 우리 모델은 최대 $M=30$ (1초)까지 예측하는데, 이것을 이어붙이면 훨씬 긴 시연 영상 생성 가능

1차: [컨텍스트10 + 예측0 + 목표1] 완성
 2차: 방금 만든 결과의 뒷부분을 새 컨텍스트로 삼아 다음 30프레임 예측
 ... 반복

- 다만 논문들이 경고했듯 **이어붙일수록 오차가 누적되고 부자연스러워질 위험**
 ⇒ 정직하게 "몇 번 이어붙였을 때부터 품질이 떨어지는지"를 실험으로 보여주는 것 자체가 좋은 분석

v2: v1 + 뼈 길이 안정화

Bone-direction 분해 + Forward Kinematics

문제: 위치(XYZ)를 관절마다 독립적으로 회귀하면, 뼈 길이(관절 간 거리)가 프레임마다 미세하게 흔들리는 현상이 실제로 관찰됨(3D 시각화로 확인).

문헌 조사 결과:

- Skeleton Consistency Loss(뼈 길이/방향 불일치에 페널티를 주는 손실항, Zanfir et al., arXiv:2109.10257)를 시도해볼 수 있으나
- "Anatomy-aware 3D Human Pose Estimation with Bone-based Pose Decomposition" (arXiv:2002.10322)은 이런 손실 기반 접근을 직접 베이스라인으로 테스트한 결과 **뼈 길이 일관성을 손실 함수만으로 강제하는 건 거의 효과가 없었다**고 명시
- 위치를 직접 예측하지 않고 "**뼈 방향 + 뼈 길이**"로 분해해서 예측한 뒤 forward kinematics로 위치를 복원하는 구조적 접근이 훨씬 효과적이었음.

우리 상황에 유리한 점:

- 일반적인 전신 자세 추정은 뼈 길이 자체를 모르는 상태(사진 한 장)에서 추정해야 하지만, 우리는 같은 시퀀스의 **컨텍스트 프레임(실제 관측된 값)**에서 진짜 뼈 길이를 이미 알고 있음
- 짧은 시간 동안 손 뼈 길이는 물리적으로 불변이므로, **뼈 길이는 컨텍스트에서 계산한 고정값을 쓰고, 모델은 뼈 "방향"(unit vector)만 예측하면** 뼈 길이 불일치가 구조적으로 원천 차단
- 또한 손목 기준 정규화를 이미 쓰고 있어 손목(root)은 항상 원점이므로 별도 예측이 필요 없음

[attachment:901d70c1-3bfb-49c5-aea9-5667b19b6c08:v2.mp4](#)