

0816_김석우

0. 중간 발표에서 틀렸던 점

0.1. 평가지표

| L2P는 원천적으로 계산 불가능한데 표준 지표로 서술돼 있었음

중간발표 내용

"평가는 위치 오차인 L2P, 회전 오차인 L2Q, 그리고 주파수 패턴을 보는 NPSS 지표를 사용하고..."

실제 확인한 것

우리 손 데이터(CSL-Daily/How2Sign, SignSpark 전처리본)는 MANO의 shape-translation 파라미터가 애초에 LMDB에 없다. 관절 회전(rot6D)만 있고 위치 정보 자체가 존재하지 않는다 — 그래서 L2P(위치 오차)는 정의 자체가 성립하지 않는다. 실제로 지금까지 학습·평가에 쓴 지표는 **측지 회전 오차(geodesic error, 단위 도)** 하나뿐이었고, L2Q·NPSS는 코드 어디에도 없었다(전체 grep으로 확인).

그래서 한 일

L2Q(쿼터니언 L2 거리)와 NPSS(Gopalakrishnan et al. 2019, 이전 SHREC 라운드 코드를 그대로 포팅)를 새 모듈(`metrics_ext.py`)로 구현했다. 구현 후 자체 검증을 거쳤다 — self-comparison(자기 자신과 비교) 결과가 세 지표 전부 정확히 0, l2q는 이론적 상한 (≤ 2)을 벗어나지 않음, geodesic 오차와 단조 관계를 보임을 확인. 다만 ****기존 논문 수치와 직접 비교 가능****이라는 표현은 그대로 못 쓴다 — 지표 이름이 같아도 데이터셋이 다르면 절대값 비교가 성립하지 않기 때문에, 이 지표들은 어디까지나 **우리 자체 SLERP 기준선 대비 상대 비교**로만 쓰기로 했다.

0.2. 입력 표현

| "손목 위치"는 데이터에 아예 없는 정보였음

중간발표 내용

"입력은 MANO 기반 15개 관절의 6D 회전 표현에 손목 위치와 속도를 추가한 형태이고..."

실제 확인한 것

위 0.1.번과 같은 이유로, 위치 채널은 손목이든 어디든 하나도 없다. 실제 입력 구성은 **회전 상태(90차원) + 프레임간 상대회전(속도 역할, 90차원) + 관측 여부 마스크(1차원) = 총 181차원**이며, 위치 정보는 전혀 포함되지 않는다.

그래서 한 일

학습 절차 섹션에 정확한 특징 구성을 다시 정리했다 (아래 "1. 데이터 전처리 & 표현 설계" 참고).

0.3. 데이터셋 선정

InterHand2.6M을 "물체 조작이라 제외"라고 서술했지만, 실제로는 제외하지 않고 나중에 채택했음

중간발표 내용

"GRAB이나 InterHand2.6M, OakInk2는 대부분 물체를 쥐고 조작하는 동작이라 제외했습니다."

실제 확인한 것

GRAB·OakInk2는 맞게 분류된 것이지만, **InterHand2.6M은 제외한 적이 없다**. 오히려 나중에 실제로 Google Drive에서 MANO 파라미터([MANO_NeuralAnnot.json](#))를 받아서, **학습에 전혀 안 쓴 도메인에 모델을 그대로 돌려보는 cross-domain 일반화 검증용**으로 썼다. 그 과정에서 관절 순서 매핑이 맞는지도 실측으로 확인했다 — MANO 표준 순서(검지 → 중지 → 소지 → 약지 → 엄지)를 적용했을 때, 엄지 관절 특유의 회전 패턴(중간 관절 회전량이 다른 관절보다 작게 나오는 프로필)이 How2Sign과 InterHand2.6M 양쪽에서 일치하는 것을 확인해서 매핑 정합성을 검증했다.

참고로 이 검증에서 나온 결과

관절 매핑은 맞았지만, 학습된 모델을 InterHand2.6M에 제로샷으로 돌리면 SLERP는커녕 Hold(가만히 있기) 기준선보다도 못한 성능이 나왔다(수어 데이터에 과적합했을 가능성).

이건 이번 회의 자료의 핵심은 아니라 상세 수치는 생략하지만, "같은 도메인 안에서는 강한 데 도메인을 벗어나면 약하다"는 그림이 이후 T=45 실험 결과와 같은 패턴이라 참고할 만하다.

그래서 한 일

데이터셋 선정 근거 표에서 InterHand2.6M을 "제외 후보"가 아니라 "일반화 검증용으로 별도 채택"으로 재분류했다.

0.4. 벤치마크 비교 가능성

방법론적으로도 짚어야 할 지점

"빠 길이가 고정된 데이터이기 때문에 L2Q·NPSS 같은 표준 지표를 그대로 사용할 수 있어서 기존 논문 수치와 직접 비교 가능한 실험 설계가 성립한다"는 부분은, 지표를 구현했는지 여부(0.1번 항목)와 별개로 **개념 자체가 성립하지 않는다**. 빠 길이가 고정돼서 지표 정의는 가능해지지만, 그렇다고 LaFAN1 같은 다른 데이터셋의 논문 수치와 절대값으로 비교할 수 있게 되는 건 아니다 — 동작 통계·정규화 방식이 데이터셋마다 다르기 때문이다.

그래서 한 일: "기존 논문과 직접 비교"라는 목표를 버리고, 처음부터 **우리 자체 test split 안에서 SLERP 기준선 대비 상대 개선율**로 평가 설계 방향을 명확히 했다. 아래 결과 섹션 전부가 이 원칙을 따른다.

1. 데이터 전처리 & 표현 설계

1.1. 관절 정합

CSL-Daily(16관절)와 How2Sign(15관절)을 공통 15관절로 통일

무엇이 문제였나

CSL-Daily는 손 하나당 16개 관절, How2Sign은 15개 관절로 저장돼 있어 그대로 합칠 수 없었다.

어떻게 확인했나

관절별 프레임간 회전 패턴을 실측 비교한 결과 인덱스 0~14는 두 데이터셋에서 거의 동일했고, CSL-Daily의 인덱스 15만 유독 회전량이 컸다(평균 8.8도/frame, 다음으로 큰 관절

의 1.5배) — 손 전체의 전역 방향(global orientation)으로 확인됐다.

그래서 한 일

- *공통 15관절(인덱스 0~14)**로 통일해서 두 데이터셋을 합쳤다.


1.2. 입력 특징 구성

| 위치 채널 없음 — 회전 + 상대회전 + 관측마스크로 구성된 181차원

구성 요소	차원
회전 상태 (state)	90
상대회전 (속도 역할)	90
관측 여부 마스크	1
합계	181

윈도우 구조

Context 10 + Transition(학습 시 5~30 랜덤, 평가 시 최대 45까지 확장) + Target 1. 정지에 가까운(움직임이 거의 없는) 윈도우는 손끝 관절 평균 회전 속도로 걸러냈다.



[이미지: [mesh_sample_grid.png](#) — 두 데이터셋 실제 클립을 입체 메쉬로 렌더링한 것. 관절 각도는 100% 실측값, 손가락 두께/뼈 길이는 일반 성인 손 템플릿 근사]

2. 모델 & 학습 절차

2.1. 베이스라인 구성

원 SILK 대비 데이터 규모에 맞춰 축소된 단일 Transformer Encoder

항목	내용
아키텍처	SILK 스타일 단일 Transformer Encoder, d=256·4층·4헤드 (약 3.2M 파라미터) — 원 논문은 d=1024·6층·8헤드
손실	L1 하나만
옵티마이저	AdamW + OneCycleLR
학습 스텝	18,000 스텝 · 배치 64
학습 데이터	CSL-Daily + How2Sign train split (오른손 기준)
학습 transition 범위	5~30 랜덤 (T=45는 학습 때 한 번도 안 봄 — 4번 결과의 핵심)

2.2. 통제 실험 3종

| 베이스라인은 그대로 둔 채 변수 하나씩만 바꿔 비교

무엇을 바꿨나

- **exp01:** 모델을 5.9배 확대(19.1M 파라미터, d=512·6층·8헤드)
- **exp02:** 절대 상태 대신 SLERP 보간 대비 ****잔차(Δ)****를 예측 (Δ -Interpolator 방식)
- **exp03:** 왼손을 오른손 좌표계로 뒤집어(mirror) 학습 데이터를 2배로 늘림

공정성 확보


나머지 조건(학습 스텝 수, 배치, 손실, test split)은 전부 베이스라인과 동일하게 고정했다.

3. 결과 — 통제 실험 3종 (학습 범위 안, $T \leq 30$)

3.1. 정량 결과

| 모델 용량 확대만 확실히 통했다

Track A experiments comparison -- CSL-Daily+How2Sign test split (never seen in training)




[이미지: [error_curves.png](#) — SLERP 대비 베이스라인·exp01~03의 측지 오차 곡선, T=5~30]

실험	T=15 오차	SLERP 대비	비고
SLERP (기준선)	8.94°	—	학습 없는 보간
베이스라인	6.04°	+32.4%	
exp01 (모델 5.9배)	5.63°	+37.0%	전 구간에서 확실히 개선
exp02 (잔차 예측)	6.19°	+30.8%	베이스라인보다 살짝 나쁨
exp03 (양손 2배)	6.03°	+32.6%	베이스라인과 사실상 동일

3.2. 정성 확인

숫자와 실제 손 모양이 같은 이야기를 하는지 확인



[이미지: [mesh_compare_CSL-Daily_2_T15.gif](#) — 같은 test 윈도우(T=15)에서 GT·SLERP·베이스라인·exp01~03을 동시에 입체 메쉬로 비교한 애니메이션, 분홍 배경이 생성 구간]

정리

학습 범위 안에서는 모델 용량을 키우는 게 유일하게 확실한 개선 레버였다. 잔차 예측·양손 데이터 복제는 이 범위 안에서는 이득이 없었다.

4. 결과 — T=45 확장 평가 (신규, 학습 범위 밖)


4.1. 왜 확인했나

| SILK 원 논문의 "재학습 없는 T=45 일반화" 주장을 우리 도메인에서 재검증

SILK 원 논문은 "T=30까지 학습해도 재학습 없이 T=45까지 깨끗하게 일반화된다고 보고한다. 이 주장을 우리 도메인에서도 검증할 필요가 있다고 판단해, 4개 지표(측지 오차·L2Q·NPSS·템플릿 기반 근사 L2P)를 전부 T=45까지 확장해 재측정했다 — 재학습 없이 기존 체크포인트 4개를 그대로 사용.

Full metric comparison, T=5..45 -- includes T=45, never trained on (dashed vertical = training cutoff)

dotted line = max T seen during training (30)



[이미지: [full_metrics_comparison.png](#) — 4개 지표 전부 T=30(학습 시 최대 길이) 지점에서 같은 이야기를 한다: 절대값 예측 모델들이 꺾여 올라감]

4.2. 핵심 발견

절대값 예측 모델은 학습 범위 밖(T=45)에서 SLERP보다 확실히 나빠진다


T=45	측지 오차	SLERP 대비
SLERP	14.98°	—
베이스라인	22.82°	52% 더 나쁨
exp01 (모델 확대)	21.22°	42% 더 나쁨
exp03 (양손 2배)	21.66°	45% 더 나쁨
exp02 (잔차 예측)	14.76°	SLERP 수준 유지 (유일)

n=500 표본으로 재확인해서 우연이 아니다. NPSS는 SLERP 0.065에서 베이스라인 0.44까지 치솟는다 — 위치가 조금 어긋나는 정도가 아니라 **움직임의 리듬 자체가 깨지는 수준**이다. 학습 안 해본 구간으로 외삽하면서 사실상 노이즈에 가까운 출력을 내는 것으로 해석된다.

4.3. 해석

분포 안에서는 절대값 예측이 이기고, 분포 밖에서는 잔차 예측이 이긴다

exp02만 버티는 이유는 구조적으로 자연스럽다 — exp02의 최종 출력은 SLERP 보간값 위에 잔차를 더하는 방식이라, 학습 범위 밖에서 잔차 예측 자체가 부정확해도 SLERP라는 "바닥"이 있어 발산을 막아준다. 3번 섹션(학습 범위 안에서는 잔차 예측이 베이스라인보다 살짝 나뉘었다)과 합쳐보면 하나의 그림이 완성된다.



[이미지: [mesh_compare_CSL-Daily_6_T45.gif](#) — 같은 비교를 T=45(학습 범위 밖)에서. exp02(잔차)의 오차가 SLERP에 가장 가까움을 시각적으로 확인 가능]

5. 종합 & 다음 단계

- exp01을 더 키워서(d=1024, 원 SILK 크기) 개선이 어디까지 이어지는지 확인
- T=45 실패의 정확한 원인 규명 — 커리큘럼 학습(점진적으로 더 긴 T를 섞어 학습)으로 완화되는지, 아니면 절대값 표현 자체의 근본적 한계인지

- InterHand2.6M 제로샷 실패 원인도 $T=45$ 실패와 같은 계열의 문제인지(둘 다 "학습 분포를 벗어나면 절대값 예측이 무너진다"는 하나의 현상일 가능성) 추가로 들여다볼 가치 있음