

0816_오은하

0816 데이터셋 모델구현

1. 개요

1.1 무엇을 만들었나

Hand Motion In-betweening: 손 동작 시퀀스에서 앞뒤(context)와 마지막(target) 프레임만 주어졌을 때, 그 사이의 빈 구간(transition)을 자연스럽게 채워 넣는 모델. 원래 전신 모션(full-body motion) in-betweening을 위해 설계된 **SILK 레시피**를 손 동작 전용으로 축소·적용함.

1.2 데이터 표현

- **MANO 손 모델 기준:** 15개 관절(엄지 제외 4개 손가락 × 3관절 + 엄지 3관절) × 6D 회전 표현(Zhou et al., 연속적인 회전 표현) = 90차원
- 관절 순서: index(검지) → middle(중지) → pinky(새끼) → ring(약지) → thumb(엄지), 각 4개 손가락씩 3관절
- **손목(wrist)/전역 회전(global_orient) 정보는 포함되지 않음** — 공식 SignSpark 시각화 코드 (`visualize.py`)를 직접 확인한 결과, `global_orient`를 항상 0으로 고정하고 90차원 값만으로 `left_hand_pose / right_hand_pose`를 복원하는 것으로 확인됨. (초반 "손목 회전+국소 회전 분리"로 이해했던 부분을 이 확인을 거쳐 "index 첫 관절 vs 나머지 14개 관절"로 정정함)

2. 데이터 파이프라인

2.1 데이터셋

- **CSL-Daily** (중국 수어) + **How2Sign** (미국 수어), 둘 다 SignSpark 프로젝트가 전처리해서 LMDB 포맷으로 배포한 것을 사용 (HuggingFace [LionelLow/SignSpark_data](#))
- CSL-Daily는 원본 96차원(앞 90차원만 사용), How2Sign은 90차원
- 이 데이터를 만들 때 손 포즈 추정에 사용된 업스트림 모델은 **WiLoR** (CVPR 2025, Imperial College London / Shanghai Jiao Tong University, arXiv 2409.12259) — 우리 팀이 직접 쓰는 모델은 아니고, WiLoR이 "오른손 전용" 좌표계를 쓰기 때문에 왼손 데이터에 flip이 필요한 이유

2.2 왼손 → 오른손 좌표계 변환 (flip)

- LMDB에는 왼손이 SMPLX-left 좌표계로 저장되어 있는데, 모델은 오른손(WiLoR) 좌표계 하나로 통일해서 학습
- 각 관절 회전행렬 R 을 `R_flip @ R @ R_flip` ($R_flip = \text{diag}(1, -1, -1)$)로 conjugate하는 연산과 수학적으로 동일하며, 6D 표현에서는 원소별 부호 곱셈(마스크 곱)으로 단순화됨
- **검증:** 직교성(orthogonality, $R \cdot R^T = I$) 및 두 번 flip 시 원본으로 복귀하는 round-trip 오차를 실제 데이터로 확인 → 정상 동작 확인

2.3 Dataset / DataLoader 구현

- 원도잉 방식: `context(10프레임) + transition(gap, 학습 시 5~30 랜덤 / 추론 시 최대 45) + target(1프레임)`
- `known_mask`: context/target = True(아는 구간), transition = False(생성 대상)
- 클립이 윈도우보다 짧으면 마지막 프레임을 반복해서 채움 (공식 로더와 동일 방식)
- 클립마다 왼손/오른손을 랜덤 선택하는 mirror augmentation 적용
- `collate_fn`: 배치 내 샘플마다 gap 길이가 달라 시퀀스 길이가 제각각이므로 `pad_sequence` 로 패딩, `valid_mask` 로 실제 데이터/패딩 구분

3. 모델 아키텍처: SILK 스타일 Transformer 인코더

3.1 입력 표현 변환

1. **0-채움**: transition 구간은 먼저 0으로 채움 (`features * known_mask`)
2. **전역/국소 분리**: 0-채움된 값 기준으로 앞 6차원(global_feat) / 나머지 84차원(local_feat) 분리하여 각각 별도 projection
3. **속도(velocity)**: 반드시 **0-채움 이후**의 값으로 계산 — 순서를 바꾸면 transition의 실제 정답 값이 속도 계산을 통해 모델에 새어 들어가는 데이터 누수(leakage) 발생

3.2 모델 구조

```
global_proj: Linear(6 → 256)
local_proj: Linear(84 → 256)
velocity_proj: Linear(90 → 256)
(세 projection 결과를 더함)
→ 위치 인코딩 적용
→ TransformerEncoder (4층, d_model=256, nhead=4, dim_feedforward=512, dropout=0.1)
→ output_head: Linear(256 → 90)
```

- `key_padding_mask` 는 PyTorch 컨벤션상 True=무시할 위치인데, 우리 `valid_mask` 는 반대(True=진짜 데이터)라서 `~valid_mask` 로 뒤집어서 전달
- 손실 함수: L1 loss, transition 구간이면서 동시에 패딩이 아닌("진짜 생성 대상") 프레임에서만 계산

3.3 위치 인코딩: 절대 vs 상대 (실험)

- **절대 위치 인코딩(최종 채택)**: 표준 sin/cos 기반 positional encoding을 입력 임베딩에 더함
- **상대 위치 인코딩(실험, 미채택)**: 두 프레임 사이의 거리(distance)마다 학습되는 스칼라 bias를 attention score에 직접 더하는 T5 스타일 구현. 자세한 내용은 6번 참고

4. 정량 평가지표

지표	설명
L2Q	예측/정답 회전을 quaternion으로 변환 후 L2 거리. double-cover(q와 -q가 같은 회전) 문제를 보정해 부호 오류로 인한 과대평가 방지
L2P (근사)	라이선스 필요 없는 근사 forward-kinematics로 손끝까지의 위치를 복원한 뒤 L2 거리 계산. 주의: 실제 MANO 캘리브레이션이 아닌 근사 뼈 길이/배치를 사용하므로 절대값을 논문/공식 수치와 직접 비교하면 안 되고, 우리 실험 내 상대 비교 용도로만 사용


지표	설명
NPSS	예측/정답 궤적의 FFT 기반 주파수 스펙트럼 유사도(에너지 가중). 값이 작을수록 움직임의 "리듬"이 정답과 비슷함을 의미

`evaluate_metrics(model, loader, n_batches=20)` 함수로 dev set에서 일괄 계산.

5. 실험 결과 (핵심)

승인된 개선 순서: 정량 평가지표 → 데이터셋 합치기 → 더 긴 학습 → 상대 위치 인코딩 → (진짜 MANO 시각화)

단계	학습 데이터	Step 수	L2Q ↓	L2P(근사) ↓	NPSS ↓
baseline	CSL-Daily만 (18,201개)	500	0.1137	0.0074	0.0627
+ 데이터셋 합치기	CSL-Daily+How2Sign (47,831개)	500	0.1120	0.0067	0.0618
+ 더 긴 학습 ★ 최종 채택	CSL-Daily+How2Sign (47,831개)	1500	0.0901	0.0058	0.0509
+ 상대 위치 인코딩 (실험)	CSL-Daily+How2Sign (47,831개)	1500	0.1005	0.0063	0.0616



5.1 데이터셋 합치기 효과

- CSL-Daily 18,201개 + How2Sign 29,630개 = 총 47,831개 (train), dev는 1,064+1,650=2,714개
- `ConcatDataset` 으로 결합, 기존 `HandInbetweeningDataset.__getitem__` 로직은 전혀 수정하지 않음
- 같은 500 step 기준으로 세 지표 모두 일관되게(작지만) 개선 — 데이터 다양성 증가의 효과가 실제로 있음을 확인
- 단, 500 step은 47,831개 중 4,000개 샘플(약 1/10 epoch)만 사용한 것이라 개선 여지가 더 있다고 판단, 다음 단계로 이어짐

5.2 더 긴 학습 효과 (가장 큰 개선)

- 500 step → 1500 step (동일 데이터, 동일 조건)
- baseline 대비 L2Q -20.8%, L2P -21.6%, NPSS -18.8% — **가장 효과가 컸던 개선**
- dev loss도 초반 ~0.15대에서 후반 ~0.08~0.09대까지 꾸준히 하락, 1500 step 시점에도 개선 추세가 남아있어 추가 학습 여지 확인

5.3 상대 위치 인코딩 실험 (미채택)

- **가설:** 간격(gap) 길이가 매번 달라지는 태스크 특성상, "절대 위치"보다 "두 프레임 사이의 상대 거리"가 더 일관된 정보를 줄 것이라 예상
- **구현:** T5 스타일 — 두 프레임 사이 거리(-127~127)마다 학습되는 스칼라 bias를 만들어 attention score에 더함 (모든 layer/head가 공유, 수치 안정성을 위해 [-5, 5]로 clamp)
- **결과:** 동일 조건(합친 데이터, 1500 step) 비교에서 세 지표 모두 오히려 악화 (L2Q +11.5%, L2P +8.6%, NPSS +21%)
- **추정 원인:**
 - 모든 layer/head가 bias 하나를 공유하는 단순화된 구현이라 원 SILK 설계보다 표현력이 부족했을 가능성
 - NaN 방지를 위한 강한 clamp(-5~5)가 상대 위치 정보의 학습을 제약했을 가능성
 - SILK 원 설계는 전신 모션처럼 훨씬 긴 시퀀스·대량 데이터에 최적화되어 있어, 손 동작처럼 짧은 시퀀스(최대 41프레임)·작은 모델(4층)·적은 학습(1500 step) 환경에서는 절대 위치 인코딩이 오히려 더 학습하기 쉬웠을 가능성
- **결론:** "시도했으나 이 규모에서는 효과 없음" — 유효한 실험 결과로 기록, **merged-1500(절대 위치 인코딩)을 최종 모델로 확정**

5.4 Naive Baseline (SLERP 보간) 비교

Transformer 모델이 실제로 유의미한지 확인하기 위해, transition 구간을 단순히 마지막 context 프레임과 target 프레임 사이 SLERP(구면 선형보간)로 채우는 naive baseline과 비교했다.

전체 비교

지표	naive (SLERP)	최종 모델 (merged-1500)
L2Q	0.0605	0.0901
L2P (근사)	0.0040	0.0058
NPSS	0.0406	0.0509

세 지표 모두 naive baseline이 더 좋게 나왔다 — 현재 모델은 아직 단순 보간을 이기지 못하는 상태.


gap 길이별 분석

이 결과의 원인을 살펴보기 위해 gap(가려진 구간) 길이별로 나눠서 다시 비교했다:

gap 구간	샘플 수	naive L2Q	모델 L2Q	모델이 naive보다 나쁜 정도
5~13	94	0.0430	0.0704	+63.7%
14~22	125	0.0721	0.0884	+22.6%
23~30	101	0.0918	0.1035	+12.7%

NPSS는 중간 구간(14~22)에서 가장 좁혀졌다가 긴 구간(23~30)에서 다시 소폭 벌어지는 비단조적 패턴을 보임


해석: gap이 길어질수록 모델과 naive의 격차가 체계적으로 좁혀진다. 짧은 gap에서는 단순 보간이 정답에 매우 가깝지만, gap이 길어질수록 "직선 경로"라는 가정이 깨지기 시작하면서 모델이 학습한 동작 패턴이 점점 유리해지는 것으로 해석된다. 이는 Motion in-betweening 연구에서 흔히 보고되는 패턴과 일치하며, 학습 규모를 늘리면 특히 긴 gap 구간에서 naive를 역전할 가능성을 시사한다.



6. 정성적 시각화

6.1 손 골격 시각화 (근사 FK)

- 실제 MANO 모델 파일([MANO_RIGHT.pkl](#))은 [mano.is.tue.mpg.de](#)에서 개인이 직접 라이선스 등록해야 받을 수 있어 자동화 불가 → **아직 미확보 상태**
- 대신 위상 구조(관절 계층, MANO 순서)는 동일하되 뼈 길이/배치가 근사치인 forward-kinematics를 직접 구현해 사용



전체적인 궤적은 그럴듯하게 따라가지만 디테일에서는 아직 부족함

6.2 최종 모델 재사용 가능하도록 정리

- 상대 위치 인코딩 실험 이후 모델 클래스가 relpos 버전으로 바뀌었기 때문에, 최종 채택 모델(merged-1500, 절대 위치 인코딩)을 다시 불러오려면 별도 클래스(`SilkHandEncoderAbsPE`)가 필요
- 체크포인트는 Google Drive에 백업되어 있어 런타임이 초기화돼도 재사용 가능

7. 한계 및 유의사항

- **L2P(근사) 지표는 절대값 비교 불가**: 실제 MANO 캘리브레이션이 아닌 근사 뼈 길이이므로, 우리 실험 내에서의 상대적 개선 여부 판단용으로만 사용
- **손목/전역 회전 정보 없음**: 90차원 특징에는 손목 회전이 포함되지 않으므로, 이 모델의 출력만으로는 손이 공간상 어디에 위치하는지는 알 수 없고 "손가락 모양의 시간적 보간"만 다룸
- **상대 위치 인코딩 결과는 우리 구현(단순화된 공유 bias)에 한정된 결론**이며, head별 분리나 clamp 완화 등 다른 구현에서는 결과가 다를 수 있음
- **실제 MANO 시각화 미완료**: 라이선스 파일 미확보로 근사 시각화 사용 중

8. 다음 단계 제안

- ☐ naive baseline과의 격차가 gap 5~13에서 +63.7%인 데 비해 gap 23~30에서는 +12.7%까지 좁혀짐 — 더 긴 학습/더 큰 모델로 스케일업 시 긴 gap 구간에서 naive를 역전하는지 확인
- ☐ MANO 라이선스 파일(`MANO_RIGHT.pkl`) 확보 후 실제 MANO 기반 시각화로 교체
- ☐ 상대 위치 인코딩 재시도: head/layer별로 bias를 분리하거나 clamp 범위를 완화해서 재실험
- ☐ 더 긴 학습(1500 step 이상, 예: 1 epoch $\approx$ 6,000 step) 또는 더 큰 모델(레이어 수/d_model 증가)로 스케일업
- ☐ L2P를 실제 MANO 기준으로 재계산해 논문/공식 수치와 비교 가능하게 만들기

9. 최종 채택 모델 요약

항목	값
모델	SILK 스타일 Transformer 인코더 (절대 위치 인코딩)
학습 데이터	CSL-Daily + How2Sign 합친 데이터 (47,831 clips)
학습 step	1,500
L2Q	0.0901
L2P (근사)	0.0058
NPSS	0.0509
baseline 대비 개선	약 19~22% (세 지표 모두)
체크포인트	<code>model_merged_step1500.pt</code> (Google Drive 백업 완료)