

0820_오은하

1. 모델 개요

Two-stage Transformer (Qin et al., SIGGRAPH Asia 2022 기반)

- **Context Transformer:** baseline(SILK 구조)과 동일. 전체 윈도우에 대해 한 번에 거친(coarse) 예측을 생성.
- **Detail Transformer:** Context의 거친 예측 결과("알려진 구간=GT, gap=Context의 예측값"으로 합성한 시퀀스)를 입력받아 다듬는 모델. Context는 완전히 고정(freeze)하고 Detail만 학습.

2. 평가 설정

- test셋 기준, T(gap 길이)=5/10/20/30 버킷별로 평가
- 표본 수 n=15,360 (전 모델 동일 조건으로 비교)
- 지표: L2Q(위치 오차), L2P(MANO 기반 포즈 오차), NPSS(움직임의 시간적 자연스러움) — 모두 낮을수록 좋음

3. Baseline vs Two-stage 결과

T	지표	Baseline	Two-stage
5	L2Q / L2P / NPSS	0.0235 / 0.0013 / 0.0043	0.0196 / 0.0011 / 0.0039
10	L2Q / L2P / NPSS	0.0407 / 0.0023 / 0.0167	0.0382 / 0.0021 / 0.0162
20	L2Q / L2P / NPSS	0.0688 / 0.0039 / 0.0448	0.0671 / 0.0039 / 0.0445
30	L2Q / L2P / NPSS	0.0887 / 0.0052 / 0.0683	0.0865 / 0.0050 / 0.0677

Two-stage가 모든 T·모든 지표에서 baseline보다 일관되게 우수. gap이 짧을수록(T=5) 개선폭이 크고(L2Q 기준 약 -16.6%), gap이 길어질수록 개선폭이 줄어드는 경향 — Context 단계의 coarse 예측 품질이 병목으로 추정됨.

4. 다중 키프레임 구조 결합

방법

gap 구간 안에 `segment==2` (전환 지점) 라벨이 있으면, 그 위치를 context/target처럼 추가 known 지점으로 노출시켜 하나의 긴 gap을 두 개의 짧은 gap으로 분할하는 구조.

- 중간 키 위치: 학습 시 `segment==2` 기준 선택(없으면 시간적 중점), 추론 시에는 `segment` 가 GT 정보라 알 수 없으므로 항상 시간적 중점 사용.
- 중간 키 값: 학습·추론 모두 Context Transformer의 예측값 사용 (GT 직접 주입 안 함 → 학습·추론 조건 일치).
- Detail 모델의 입력 구성은 Two-stage와 동일하며, 중간 키 위치를 loss·채점에서 제외한다는 점만 다름.
- GT 대신 Context 예측값을 쓰는 이유: 학습 때 GT를 넣으면, 정답을 모르는 추론 시점의 입력과 조건이 달라져서(exposure bias) 성능이 불안정해질 수 있음. 학습·추론을 항상 동일하게 맞춰서 이 문제를 피함.

결과 (동일 조건, n=15,360)

T	지표	Two-stage	다중 키프레임
5	L2Q / L2P / NPSS	0.0196 / 0.0011 / 0.0039	0.0196 / 0.0011 / 0.0049
10	L2Q / L2P / NPSS	0.0382 / 0.0021 / 0.0162	0.0371 / 0.0020 / 0.0169
20	L2Q / L2P / NPSS	0.0671 / 0.0039 / 0.0445	0.0659 / 0.0038 / 0.0453
30	L2Q / L2P / NPSS	0.0865 / 0.0050 / 0.0677	0.0857 / 0.0050 / 0.0684

test셋 평가 결과 (n=15,360)

T	지표	Baseline	Two-stage	다중 키프레임
5	L2Q / L2P / NPSS	0.0235 / 0.0013 / 0.0043	0.0196 / 0.0011 / 0.0039	0.0196 / 0.0011 / 0.0049
10	L2Q / L2P / NPSS	0.0407 / 0.0023 / 0.0167	0.0382 / 0.0021 / 0.0162	0.0371 / 0.0020 / 0.0169
20	L2Q / L2P / NPSS	0.0688 / 0.0039 / 0.0448	0.0671 / 0.0039 / 0.0445	0.0659 / 0.0038 / 0.0453
30	L2Q / L2P / NPSS	0.0887 / 0.0052 /	0.0865 / 0.0050 /	0.0857 / 0.0050 /

T	지표	Baseline	Two-stage	다중 키프레임
		0.0683	0.0677	0.0684

해석

- **L2Q/L2P(위치 정확도)**: 다중 키프레임 구조가 Two-stage보다 더 개선됨. gap이 길 수록(T=20, 30) 개선폭이 더 큼.
- **NPSS(움직임의 자연스러움)**: 반대로 모든 T에서 소폭 악화됨. 중간 키 지점에서 Detail이 더 이상 다듬지 않다 보니, 그 지점 앞뒤 연결이 매끄럽지 않아지는 것으로 추정.

→ 다중 키프레임 구조는 위치 정확도와 움직임 자연스러움 사이에 트레이드오프가 있음. 최종 채택 여부는 어느 지표를 우선할지에 대한 팀 논의가 필요함.


5. MANO 관절 시각화로 트레이드오프 검증

방법

test셋에서 T=5/10/20/30별로 클립을 뽑아, 같은 윈도우에 대한 GT/Baseline/Two-stage/다중 키프레임 예측을 MANO 손 관절 3D 애니메이션으로 나란히 비교. 육안 확인 외에, 프레임 간 변화량(이전 프레임 대비 얼마나 움직였는지)을 직접 측정해서 "어디서 부자연스러운 움직임이 나오는지" 정량적으로 확인함.


비교 GIF (GT / Baseline / Two-stage / 다중 키프레임)

T=5




T=10

T=10 | frame 1/21




T=20

T=20 | frame 1/31



T=30

T=30 | frame 1/41



결과

- **Baseline:** 특정 구간이 아니라 전체적으로 GT보다 움직임이 뺏뺏함(프레임 간 변화량이 항상 GT보다 큼) — 한 번에 통째로 예측하는 구조의 한계로 해석.
- **Two-stage:** 프레임 간 변화량이 GT와 거의 일치 — 4개 방법 중 가장 자연스러운 움직임. NPSS가 가장 좋았던 정량 결과와 일치.
- **다중 키프레임:** 평균적으로는 무난하지만, **중간 키프레임 경계 지점에서만 프레임 간 변화량이 GT/Two-stage보다 뚜렷하게 튀는 패턴**이 T=5/10/20/30 전부에서 일관되게 확인됨 — 4번에서 발견한 NPSS 저하의 원인(경계에서의 "이음매")을 시각적으로도 확인.

→ 정량 지표(NPSS)로만 보였던 트레이드오프가 실제 움직임에서도 같은 지점(중간 키프레임 경계)에서 나타남을 확인. 이 문제를 완화하기 위해 loss 가중치를 조정하는 방향을 실제로 시도해봄

6. 추가 개선 시도: loss 가중치 조정 (soft-loss)

방법

다중 키프레임의 NPSS 저하를 개선하기 위해, 중간 키프레임 위치를 loss에서 완전히 제외하는 대신

낮은 가중치(0.3)를 줘서 일부만 학습에 반영되도록 수정. 나머지 구조(입력 구성, 추론, 평가)는 Two-stage와 동일.

결과 (동일 조건, n=15,360)

T	지표	Two-stage	다중 키프레임(원래)	다중 키프레임(soft, 0.3)
5	L2Q / L2P / NPSS	0.0196 / 0.0011 / 0.0039	0.0196 / 0.0011 / 0.0049	0.0217 / 0.0012 / 0.0042
10	L2Q / L2P / NPSS	0.0382 / 0.0021 / 0.0162	0.0371 / 0.0020 / 0.0169	0.0391 / 0.0022 / 0.0164
20	L2Q / L2P / NPSS	0.0671 / 0.0039 / 0.0445	0.0659 / 0.0038 / 0.0453	0.0676 / 0.0039 / 0.0447
30	L2Q / L2P / NPSS	0.0865 / 0.0050 / 0.0677	0.0857 / 0.0050 / 0.0684	0.0872 / 0.0051 / 0.0680

해석

soft-loss 버전은 Two-stage보다 모든 T·모든 지표에서 더 나쁘게 나옴. NPSS는 원래 다중 키프레임보다 소폭 개선됐지만,
그 대신 원래 다중 키프레임이 가진 위치 정확도(L2Q/L2P) 장점을 대부분 잃음. loss 가중치를 낮추는 방식만으로는
위치 정확도와 자연스러움을 동시에 잡기 어렵다는 것을 확인함 — 이 방향의 개선 시도는 여기서 마무리.

7. 남은 논의 사항

- 다중 키프레임 채택 여부: 위치 정확도(L2Q/L2P) 개선과 자연스러움(NPSS) 저하 중 어느 쪽을 우선할지 팀 논의 필요